

Beyond Loss Curves

Spectral Monitoring for LLM Pretraining

基于谱结构的大模型预训练监控框架

14 Models

4 Architectures

~340 Checkpoints

2 Scales Validated

组会汇报 · 2026-05-27

预训练的 "盲飞" 现状

The Blind Flight Problem

MODEL	COST	GPUS	TIME
GPT-4	~\$100M+	数万 A100	3-6 月
Llama-3- 70B	~\$30M	16K H100	~3 月
DeepSeek- V3	~\$5.5M	2048 H800	2 月

整个训练过程中，工程师判断"训练是否正常"的核心指标只有一个：**training loss**



\$100M+

Investment

Only 1 instrument:
training loss

Loss 的四个根本性盲区 Fundamental Blind Spots

盲区 1

Loss ↓ ≠ 模型变好

Memorization 也能降 loss, 但泛化结构在退化

盲区 2

无法跨模型比较

1B 的 loss=3.0 与 70B 的 loss=3.0 含义完全不同

盲区 3

不知何时降 LR

Cosine/WSD 都是人为预设, 缺乏模型自身信号

盲区 4

没有早期预警

结构退化时 loss 仍在下降——直到不可逆

核心洞察 (Core Insight): 智能不是记住信息, 而是发现结构——我们需要直接测量结构

PART I

两个核心指标

Two Spectral Metrics: SR/d & α

指标 1: SR/d Normalized Stable Rank

$$\text{SR}(W) = \|W\|_F^2 / \sigma_1^2$$
$$\rightarrow \text{SR}/d = \text{SR}(W) / d_{\text{model}}$$

- **物理含义:** 矩阵用了多少百分比的可用维度空间
- **数学本质:** $\text{SR} = \exp(H_2)$, 即 Rényi-2 谱熵的指数
- **计算成本:** $O(mn)$, 7B 全部层 ~5 min

SR/d ↓ = 谱熵减少 = 信息在压缩
这不是类比——是数学恒等式

~0.40

随机初始化 (Random Init)

↓ 训练 ↓

~0.05

训练完成 (Fully Trained)

压缩 ~8× → $\Delta H_2 \approx -2.0$ nats
(Universal across all models!)

指标 2: α Power-Law Exponent

$$P(\lambda) \sim \lambda^{-\alpha} \quad (\text{ESD of } W^T W)$$

- **物理含义:** 权重矩阵的内部结构质量
- **理论基础:** Heavy-Tail Self-Regularization (HTSR)
- **$\alpha \downarrow = \text{heavy-tail} \uparrow = \text{特征相关性} \uparrow = \text{泛化} \uparrow$**

关键发现: α 不是单调下降的——在大模型上它会反转 (Reversal)!

A 范围	状态	含义
> 6	Random	接近 Marchenko-Pastur
$4 \sim 6$	Bulk + Spikes	部分结构化
$2 \sim 4$	Heavy-Tail	良好自正则化 $\checkmark$
< 2	Over-trained	Rank collapse 风险

Martin & Mahoney (JMLR 2021)

训练好的网络层遵循 power-law 分布

两个指标的协同 Dual-Metric Dynamics





Fig 1. Spectral Phase Portrait — 所有模型在 $(SR/d, \alpha)$ 空间中的训练轨迹。小模型收敛到左下角 (压缩+有序)，大模型停滞在高 α 区域

PART II

核心发现

Key Findings from 14 Models × 4 Architectures

发现 1: SR/d 通用收敛 Universal Convergence




$$SR/d(\infty) = 0.040 + 0.61 / \sqrt{d}$$

- **14 个模型全部收敛到 0.04-0.07**
- 只由层宽度 d 决定，**与深度无关**
- OLMo-2-13B 和 32B (同 $d=5120$): **SR/d 完全相同 (0.043)**

通用压缩定律: $\Delta H_2 = -2.04 \pm 0.17$ nats
所有 Transformer 精确压缩 ~ 2 nats 谱熵

发现 2: α Reversal Structural Degradation Signal



Loss 下降，但结构在退化!


- **OLMo-2-13B:** α 从 4.25 反转到 6.95 ($\Delta\alpha = +2.71$)
- 5/8 大模型展现 reversal，跨架构一致
- **MLP 驱动:** α_{mlp} 上升而 α_{attn} 稳定

直觉 (INTUITION)

嘈杂环境搭积木: 该学的学完后 (手没方向), 噪声把精细结构震坏($\alpha\uparrow$)。

降 LR = 减小振动 = 保护结构

发现 3: 预测下游性能 Predictive Power



-0.90

Spearman ρ

0.63

R^2 (单变量)

0.84


R^2 (+log N)

N=102 (6 models $\times$ 17 checkpoints $\times$ 5 benchmarks)

$$\text{Perf} \approx -0.248 \cdot \log_{10}(SR/d) + 0.062 \cdot \log_{10}(N) - 0.365$$

不需要训练数据、测试数据或 loss，仅从权重就能预测 84% 的下游方差

发现 4: 结构相变 Phase Transition at $N \approx 1.7B$



< 1.7B: α 能降到 <3 (结构成熟)
 > 1.7B: α stuck >5 (结构不成熟)


$$\alpha(N) \approx 2.65 + 2.1 \times \sigma((\log_{10} N - 9.23) / 0.07)$$

Sigmoid fit $R^2 = 0.97$

"大模型难训" 不只是数据量问题——大模型根本性地更难结构化

发现 5: MLP 是结构瓶颈

MLP as Structural Bottleneck



MODEL	A_ATTEN	A_MLP	GAP
OLMo-2-1B	1.35	3.56	2.21
OLMo-2-32B	3.44	7.59	4.15
Mistral-7B	3.79	9.22	5.43

Attention 已结构化 ($\alpha < 4$), MLP 仍是随机噪声 ($\alpha > 7$)

→ 优先增加 MLP 容量 (更宽 FFN / MoE), 而非更多 attention heads

PART III

从诊断到行动

α -Guided Adaptive LR Schedule

α -Guided Schedule

Data-Driven LR Decay

每 500 步测量 α (2 层 SVD, ~5s)



检测: $d\alpha/dt > 0$ 连续 3+ 次?



触发 LR Decay (linear to $\eta_{\min}$)

```
# (stable_fraction) if
alpha_increasing(window=3):
start_lr_decay() #
"stable"
```

核心优势

- 自动适应不同规模: 410M→83%, 1B→74%
- 自动适应不同数据: 无需人工调参
- 信号来自模型自身结构


理论依据 (THEORETICAL BASIS)

α reversal = SGD noise > spectral gap

降 $\eta \rightarrow \text{noise} \propto \eta^2$ 下降 $\rightarrow$ 恢复
SNR > 1

(Wedin's $\sin-\Theta$ theorem bounds subspace rotation)

实验验证: 410M 3-Way FineWeb-Edu, 10B tokens, 2 seeds



SCHEDULE	LOSS	A	AVG $\uparrow$
Cosine	2.931	2.68	0.459
WSD	2.874	2.47	0.467
α-Guided	2.877	2.44	0.468

vs Cosine

LAMBADA

WSD

自动匹
配

Scale-Up: 1B 验证

Advantage Amplifies with Scale

SCHEDULE	LOSS	A	SR/D	AVG ↑
Cosine	2.739	4.05	0.056	0.486
WSD	2.701	4.01	0.054	0.494
α-Guided	2.709	3.87	0.054	0.498


α-Guided 首次明确超越 WSD (+0.98%)，而非仅持平

跨规模趋势

对比	410M	1B
α-Guided vs Cosine	+1.95%	+2.56%
α-Guided vs WSD	+0.11%	+0.98%
Decay point	83%	74%
LAMBADA ↑	+6.3%	+10.2%

优势随规模放大: 预计 7B+ 更显著

跨架构验证 Cross-Architecture Validation



GPT-NeoX (Pythia)

6 scales, 150 ckpts


OLMo-2

4 scales, 100 ckpts

Mistral (GQA)

v0.1 + v0.3, $\Delta\alpha < 0.02$

谱结构热力图 Spectral Heatmaps




Left: α evolution across 10 models over training. Center: Eigenvalue concentration (Pythia). Right: SR/d compression ratio (Pythia)

PART IV

实践价值

Practical Applications for Pretraining Engineers

训练监控仪表盘 Health Monitoring Dashboard



四级警报系统



HEALTHY

$d\alpha/dt < 0 \rightarrow$ 继续训练



PLATEAU

$|d\alpha/dt| \approx 0 \rightarrow$ 考虑 decay



REVERSAL

$d\alpha/dt > 0 \times 3 \rightarrow$ 立即降 LR



EXHAUSTED

$\alpha > 4 + \uparrow \rightarrow$ 需要更多容量

成本: $< 0.05\%$ 训练 compute

Post-hoc 模型体检

5-Minute Model Audit

案例: K2-65B 诊断

SR/d	0.036	偏低
α	5.09	不成熟
Reversal	$\Delta\alpha = +0.65$	已退化

诊断: 训练不充分 (only 1.4T tokens, D/N=21)

外部验证: K2 在 15/21 benchmark 低于 Llama-2-70B

5 分钟测量 = 跑几天 benchmark 的结论

完整模型审计表

MODEL	SR/D	A	判定
Pythia-1B	0.050	2.78	成熟
OLMo-2-1B	0.064	2.37	成熟
OLMo-2-13B	0.043	6.95	不成熟
OLMo-2-32B	0.043	5.25	不成熟
Mistral-7B	0.040	6.13	不成熟
K2-65B	0.036	5.09	严重不足

对预训练的建议 Actionable Recommendations

建议 1: 不用 Cosine

Cosine 过早衰减 LR, 浪费"结构形成黄金期"。

WSD 或 α -Guided 保持高 LR 到 74-83%
→ benchmark +2-2.6%

建议 2: 数据远超 Chinchilla

结构成熟需要 15-25× Chinchilla 推荐量

1B: ~300B tokens
7B: ~3.5T tokens
13B: 远超 5T tokens

建议 3: 关注 MLP 容量

大模型 Attn 已结构化, **MLP 是瓶颈** (gap 可达 5.4)

→ 更宽 FFN / MoE 增加 MLP 容量

总结: 发布前 5 分钟谱体检 — SR/d 接近 $0.040 + 0.61/\sqrt{d}$ 且 $\alpha < 4$ → 训练充分

与现有方法对比

Comparison with Existing Methods

CAPABILITY	TRAINING LOSS	WEIGHTWATCHER (MARTIN 2021)	SCALING LAWS (CHINCHILLA)	OURS
实时监控 (Real-time)	✓	✗ (post-hoc)	✗	✓
跨模型可比 (Scale-free)	✗	✓	✗	✓
检测结构退化 (Detect degradation)	✗	✗	✗	✓ (α reversal)
预测下游性能 (Predict perf)	✗	部分 (r~0.7)	仅 loss	$\rho=-0.90$, $R^2=0.84$
指导训练决策 (Guide training)	✗	✗	仅数据量	✓ (+2.56% @1B)
开销 (Cost)	0	分钟级	0	<0.05% compute

我们的方法首次将 post-hoc 谱分析升级为 实时训练指导工具，且在预测精度和可操作性上全面超越

理论基础 Theoretical Foundation

信息论恒等式

$$\text{SR}(\mathbf{W}) = \exp(H_2) = 1 / \sum p_i^2$$

where $p_i = \sigma_i^2 / \|\mathbf{W}\|_F^2$

Stable Rank = Participation Ratio $\approx \exp(\text{Rényi-2 谱熵})$

α Reversal 的 SNR 解释

$$\text{SNR}(t) = \|\mathbb{E}[\nabla \mathbf{L}]\|^2 / \text{Var}[\nabla \mathbf{L}]$$

$\alpha \text{ reversal} \Leftrightarrow \text{SNR}(t) < 1$

降 η 使 $\text{noise} \propto \eta^2 \downarrow \rightarrow$ 恢复 $\text{SNR} > 1$

Wedin 子空间稳定性

$$\|\sin\Theta(\mathbf{U}_k, \mathbf{U}'_k)\| \leq \eta \cdot \|\nabla \mathbf{L}\| / \nu_k(\mathbf{W})$$

α -guided 在 ν_k 缩小时减小 $\eta \rightarrow$ 最小化子空间旋转

Langevin 动力学

SGD = 梯度下降 + 有效温度扩散:

$$d\sigma_i = -\eta \partial \mathbf{L} / \partial \sigma_i dt + \sqrt{(2\eta T_{\text{eff}})} dB_i$$

Higher $T_{\text{eff}} \rightarrow$ spectrum blurs $\rightarrow \alpha \uparrow$

$$T_{\text{eff}} = \eta \cdot C_{\text{batch}}$$

总结与贡献 Summary

四个层次的贡献

- **描述性 (Descriptive):** SR/d 通用收敛 + α reversal 发现
- **预测性 (Predictive):** 仅从权重预测 84% 下游方差
- **指导性 (Prescriptive):** α -guided schedule +2.56% @ 1B
- **诊断性 (Diagnostic):** 5 min post-hoc 模型审计

科学意义

- 通用压缩定律: $\Delta H_2 \approx -2$ nats
- 结构相变: $N \approx 1.7B$ 阈值
- Loss $\neq$ Quality 的直接证据
- $SR = \exp(H_2)$ 严格桥梁

实验规模

14

Models

4

Architectures

~340

Checkpoints

930x

Scale Range

Target: NeurIPS 2026

14 publication-quality figures
Comprehensive theory framework
38 citations in Related Work

Thank You

Beyond Loss Curves: Spectral Monitoring for LLM Pretraining

仅从权重矩阵的谱结构，就能诊断训练健康度、预测下游性能、指导 LR 决策
——成本 <0.05% 训练 *compute*

