

Beyond Loss Curves

Spectral Monitoring for LLM Pretraining

基于谱结构的大模型预训练监控框架

14 Models

4 Architectures

~340 Checkpoints

2 Scales Validated

组会汇报 · 2026-05-27

预训练的 "盲飞" 现状

The Blind Flight Problem

Model	Cost	GPUs	Time
GPT-4	~\$100M+	数万 A100	3-6 月
Llama-3-70B	~\$30M	16K H100	~3 月
DeepSeek-V3	~\$5.5M	2048 H800	2 月

\$100M+ Investment

Only 1 instrument:
training loss

整个训练过程中，工程师判断“训练是否正常”的核心指标只有一个：training loss

Loss 的四个根本性盲区

Fundamental Blind Spots

盲区 1

Loss ↓ ≠ 模型变好

Memorization 也能降 loss,
但泛化结构在退化

盲区 2

无法跨模型比较

1B 的 loss=3.0 与 70B 的
loss=3.0 含义完全不同

盲区 3

不知何时降 LR

Cosine/WSD 都是人为预设,
缺乏模型自身信号

盲区 4

没有早期预警

结构退化时 loss 仍在下降——
直到不可逆

核心洞察: 智能不是记住信息, 而是发现结构——我们需要直接测量结构

PART I

两个核心指标

Two Spectral Metrics: SR/d & α

指标 1: SR/d

Normalized Stable Rank

$$SR(W) = \frac{\|W\|_F^2}{\sum \sigma_i^2} \rightarrow SR/d = \frac{SR(W)}{d_{model}}$$

物理含义: 矩阵用了多少百分比的可用维度空间

数学本质: $SR = \exp(H_2)$, 即 Rényi-2 谱熵的指数

计算成本: $O(mn)$, 7B 全部层 ~5 min

~0.40

随机初始化 (Random Init)

↓ 训练 ↓

~0.05

训练完成 (Fully Trained)

压缩 $\sim 8\times \rightarrow \Delta H_2 \approx -2.0$ nats
(Universal across all models!)

SR/d ↓ = 谱熵减少 = 信息在压缩
这不是类比——是数学恒等式

指标 2: α

Power-Law Exponent

$$P(\lambda) \sim \lambda^{-\alpha} \quad (\text{ESD of } W^T W)$$

物理含义: 权重矩阵的内部结构质量

理论基础: Heavy-Tail Self-Regularization (HTSR)

$\alpha \downarrow$ = heavy-tail $\uparrow$ = 泛化 $\uparrow$


**关键发现: α 不是单调下降的——
在大模型上它会反转 (Reversal)!**

α 范围	状态	含义
> 6	Random	接近 Marchenko-Pastur
$4 \sim 6$	Bulk+Spikes	部分结构化
$2 \sim 4$	Heavy-Tail	良好自正则化 $\checkmark$
< 2	Over-trained	Rank collapse 风险

Martin & Mahoney (JMLR 2021)
训练好的网络层遵循 power-law 分布

两个指标的协同

Spectral Phase Portrait



所有模型在 $(SR/d, \alpha)$ 空间中的训练轨迹。小模型收敛到左下角，大模型停滞在高 α 区域


PART II

核心发现

Key Findings from 14 Models × 4 Architectures

发现 1: SR/d 通用收敛

Universal Convergence




$$SR/d(\infty) = 0.040 + 0.61 / \sqrt{d}$$

14 个模型全部收敛到 0.04-0.07
只由层宽度 d 决定, 与深度无关
OLMo-2-13B 和 32B (同 $d=5120$):
 SR/d 完全相同 (0.043)

通用压缩定律: $\Delta H_2 = -2.04 \pm 0.17$ nats
所有 Transformer 精确压缩 ~ 2 nats 谱熵

发现 2: α Reversal

Structural Degradation Signal



Loss 下降，但结构在退化！

OLMo-2-13B: α 从 4.25 反转到 6.95 ($\Delta\alpha = +2.71$)

5/8 大模型展现 reversal, 跨架构一致


MLP 驱动: α_{mlp} 上升而 α_{attn} 稳定

直觉 (Intuition)

嘈杂环境搭积木: 该学的学完后(手没方向), 噪声把精细结构震坏($\alpha \uparrow$)。

降 LR = 减小振动 = 保护结构

发现 3: 预测下游性能



Predictive Power

-0.90

Spearman ρ

0.63

R^2 (单变量)

0.84


R^2 (+log N)

N=102 (6 models $\times$ 17 checkpoints $\times$ 5 benchmarks)

$$\text{Perf} \approx -0.248 \cdot \log_{10}(SR/d) + 0.062 \cdot \log_{10}(N) - 0.365$$

不需要训练/测试数据或 loss, 仅从权重
就能预测 84% 的下游方差

发现 4: 结构相变



Phase Transition at $N \approx 1.7\text{B}$

$< 1.7\text{B}$: α 能降到 < 3 (结构成熟)
 $> 1.7\text{B}$: α stuck > 5 (结构不成熟)


$$\alpha(N) \approx 2.65 + 2.1 \times \sigma((\log_{10} N - 9.23) / 0.07)$$

Sigmoid fit $R^2 = 0.97$

**"大模型难训" 不只是数据量问题
——大模型根本性地更难结构化**

发现 5: MLP 是结构瓶颈

MLP as Structural Bottleneck



Model	α_{attn}	α_{mlp}	Gap
OLMo-2-1B	1.35	3.56	2.21
OLMo-2-32B	3.44	7.59	4.15
Mistral-7B	3.79	9.22	5.43

Attention 已结构化 ($\alpha < 4$), MLP 仍随机 ($\alpha > 7$)

→ 优先增加 MLP 容量 (更宽 FFN / MoE)

PART III

从诊断到行动

α -Guided Adaptive LR Schedule

α -Guided Schedule

Data-Driven LR Decay

每 500 步测量 α (2 层 SVD, $\sim 5s$)



检测: $d\alpha/dt > 0$ 连续 3+ 次?



触发 LR Decay (linear $\rightarrow \eta_{\min}$)

核心优势

自动适应不同规模: 410M $\rightarrow$ 83%, 1B $\rightarrow$ 74%

自动适应不同数据: 无需人工调参

信号来自模型自身结构

理论依据 (Theoretical Basis)


α reversal = SGD noise > spectral gap

降 $\eta \rightarrow \text{noise} \propto \eta^2$ 下降 $\rightarrow$ 恢复 SNR > 1

(Wedin's sin- Θ theorem bounds subspace rotation)

实验验证: 410M 3-Way

FineWeb-Edu, 10B tokens, 2 seeds



Schedule	Loss	α	Avg $\uparrow$
Cosine	2.931	2.68	0.459
WSD	2.874	2.47	0.467
α -Guided	2.877	2.44	0.468

+1.95%

vs Cosine

+6.3%

LAMBADA $\uparrow$

$\approx$ WSD

自动匹配

Scale-Up: 1B 验证

Advantage Amplifies with Scale

Schedule	Loss	α	SR/d	Avg $\uparrow$
Cosine	2.739	4.05	0.056	0.486
WSD	2.701	4.01	0.054	0.494
α-Guided	2.709	3.87	0.054	0.498

α -Guided 首次明确超越 WSD (+0.98%)，而非仅持平



跨规模趋势

对比	410M	1B
α -Guided vs Cosine	+1.95%	+2.56%
α -Guided vs WSD	+0.11%	+0.98%
Decay point	83%	74%
LAMBADA $\uparrow$	+6.3%	+10.2%

优势随规模放大: 预计 7B+ 更显著

跨架构验证

Cross-Architecture Validation



GPT-NeoX (Pythia)

6 scales, 150 ckpts

OLMo-2

4 scales, 100 ckpts




Mistral (GQA)

v0.1 + v0.3, $\Delta\alpha < 0.02$

谱结构热力图

Per-Layer Spectral Dynamics

Per-Layer Spectral Dynamics: Explosive Ordering + Structural Divergence




PART IV

实践价值

Practical Applications for Pretraining Engineers

训练监控仪表盘



Health Monitoring Dashboard

● **HEALTHY**

$d\alpha/dt < 0 \rightarrow$ 继续训练

● **PLATEAU**

$|d\alpha/dt| \approx 0 \rightarrow$ 考虑 decay

● **REVERSAL**

$d\alpha/dt > 0 \times 3 \rightarrow$ 立即降 LR

● **EXHAUSTED**

$\alpha > 4 + \uparrow \rightarrow$ 需要更多容量

成本: $< 0.05\%$ 训练 compute

Post-hoc 模型体检

5-Minute Model Audit

案例: K2-65B 诊断

SR/d	0.036	偏低
α	5.09	不成熟
Reversal	$\Delta\alpha = +0.65$	已退化

诊断: 训练不充分 (only 1.4T tokens, D/N=21)
外部验证: K2 在 15/21 benchmark 低于 Llama-2-70B

5 分钟测量 = 跑几天 benchmark 的结论

完整模型审计表

Model	SR/d	α	判定
Pythia-1B	0.050	2.78	✓ 成熟
OLMo-2-1B	0.064	2.37	✓ 成熟
OLMo-2-13B	0.043	6.95	✗ 不成熟
OLMo-2-32B	0.043	5.25	⚠ 不成熟
K2-65B	0.036	5.09	✗ 严重不足

对预训练的建议

Actionable Recommendations

建议 1: 不用 Cosine

Cosine 过早衰减 LR, 浪费"结构形成黄金期"。

WSD 或 α -Guided 保持高 LR 到 74-83%
→ benchmark +2-2.6%

建议 2: 数据远超 Chinchilla

结构成熟需要 15-25× Chinchilla 推荐量

1B: ~300B tokens
7B: ~3.5T tokens
13B: 远超 5T tokens

建议 3: 关注 MLP 容量

大模型 Attn 已结构化,
MLP 是瓶颈 (gap 可达 5.4)

→ 更宽 FFN / MoE 增加 MLP 容量

总结: 发布前 5 分钟谱体检 — SR/d 接近 $0.040 + 0.61/\sqrt{d}$ 且 $\alpha < 4$ → 训练充分

与现有方法对比

Comparison with Existing Methods

Capability	Loss	WeightWatcher	Scaling Laws	Ours
实时监控	✓	X (post-hoc)	X	✓
跨模型可比	X	✓	X	✓
检测结构退化	X	X	X	✓ (α reversal)
预测下游性能	X	部分 ($r \sim 0.7$)	仅 loss	$\rho = -0.90$, $R^2 = 0.84$
指导训练决策	X	X	仅数据量	✓ (+2.56% @1B)
开销	0	分钟级	0	<0.05% compute

首次将 post-hoc 谱分析升级为实时训练指导工具，且在预测精度和可操作性上全面超越

理论基础

Theoretical Foundation

信息论恒等式

$$\text{SR}(W) = \exp(H_2) = 1 / \sum p_i^2$$

where $p_i = \sigma_i^2 / \|W\|^2 F$

α Reversal 的 SNR 解释

$$\text{SNR}(t) = \|E[\nabla L]\|^2 / \text{Var}[\nabla L]$$

α reversal $\Leftrightarrow \text{SNR}(t) < 1$

降 η 使 noise $\propto \eta^2 \downarrow \rightarrow$ 恢复 $\text{SNR} > 1$

Wedin 子空间稳定性

$$\|\sin\theta(U_k, U'_k)\| \leq \eta \cdot \|\nabla L\| / \gamma_k(W)$$

α -guided 在 γ_k 缩小时减小 $\eta \rightarrow$ 最小化子空间旋转

Langevin 动力学

SGD = 梯度下降 + 有效温度扩散:
 $d\sigma_i = -\eta \partial L / \partial \sigma_i dt + \sqrt{2\eta T_{\text{eff}}} dB_i$
Higher $T_{\text{eff}} \rightarrow$ spectrum blurs $\rightarrow \alpha \uparrow$

总结与贡献

四个层次的贡献

描述性 (Descriptive): SR/d 通用收敛 + α reversal

预测性 (Predictive): 仅从权重预测 84% 下游方差

指导性 (Prescriptive): α -guided +2.56% @ 1B

诊断性 (Diagnostic): 5 min post-hoc 模型审计

科学意义

通用压缩定律: $\Delta H_2 \approx -2$ nats

结构相变: $N \approx 1.7B$ 阈值

Loss $\neq$ Quality 的直接证据

SR = $\exp(H_2)$ 严格桥梁

Summary

14

Models

4

Architectures

~340

Checkpoints

930x

Scale Range

Target: NeurIPS 2026

14 publication-quality figures
38 citations in Related Work

Thank You

Beyond Loss Curves: Spectral Monitoring for LLM Pretraining

仅从权重矩阵的谱结构，就能诊断训练健康度、预测下游性能、
指导 LR 决策——成本 <0.05% 训练 compute

Q & A