

Beyond Loss Curves: Spectral Monitoring for LLM Pretraining

仅从模型权重的谱结构（spectral structure），就能诊断训练健康度、预测下游性能、
指导学习率决策——成本不到训练的 0.05%

12 Models（模型）

3 Architecture Families（架构家族）

70M – 65B Parameters（参数）

~250 Checkpoints 分析

痛点：价值 5 亿美元的盲区

训练一个前沿 LLM（大语言模型）花费 \$100–500M，几千块 GPU 跑几个月，处理万亿 tokens（词元）。全程唯一的实时诊断指标：**training loss（训练损失）**。

- Loss 在降，但模型可能在死记硬背（memorization）而非真正学习
- Loss 不可跨模型比较——1B 的 loss=3 和 70B 的 loss=3 含义完全不同
- 不知道什么时候该降学习率——全靠经验和拍脑袋
- 没有早期预警——等 loss spike（尖峰）出现时损失已造成



开一架 5 亿美元的飞机

驾驶舱里只有一个高度计

不知道引擎健康度、油效、结构完整性.....

SR/d — Stable Rank / Hidden Dim

(稳定秩 / 隐藏维度)

衡量压缩程度——这层权重用了多少比例的维度空间。

$$SR = ||W||^2_F / \sigma^2_1 \approx \exp(H_{\text{Rényi-2}})$$

初始化时 $\approx 40\%$ (随机分散) $\rightarrow$ 训练后 $\approx 5\%$ (高度集中)

α — Power-Law Exponent

(幂律指数)

衡量结构质量——权重是否形成了有组织的 heavy-tail (重尾) 特征分布。

$\alpha > 6$ = 随机噪声 $\rightarrow \alpha \in [2, 4]$ = 结构成熟

α 的四个区间

RANDOM
(随机)

$$\alpha > 6$$

PARTIAL (部分结构化)

$$\alpha \in [4, 6]$$


HEAVY-TAIL (成熟)

$$\alpha \in [2, 4]$$

COLLAPSE (崩塌)

$$\alpha < 2$$

💡 关键: $SR = \exp(\text{Rényi-2 熵})$ 。SR/d 下降 = 谱熵减少 = 信息在压缩。这不是类比, 是数学恒等式。




五项核心贡献



P1: 通用压缩定律

SR/d 收敛到由 d 决定的常数 ($\approx 0.040 + 0.61/\sqrt{d}$)。所有模型压缩 ~ 2 nats Rényi-2 谱熵。



P2: 性能预测器

SR/d 与下游性能 (downstream performance) 相关系数 $r = -0.92$ ，仅从权重预测 75% 的性能方差。



P3: α 反转 = 结构退化

当 $d\alpha/dt > 0$ 时，结构在退化——Loss 看不到。13B 规模反转最大 ($\Delta\alpha = +2.71$)。



P4: 自适应 LR Schedule

α -Guided 自动找到 decay (衰减) 时机，匹配手调 WSD、比 Cosine 好 2% benchmark。



P5: Post-hoc 训练审计

5 分钟测量即可判断模型训练是否充分。K2-65B 诊断结果被外部 benchmark 完全验证。

实验覆盖范围

12

MODELS (模型)

930×

SCALE RANGE (规模跨度)


3

ARCH FAMILIES (架构家族)

~250

CHECKPOINTS (检查点)


* Mistral SR/d 为方形层 (d×d projection) 值。完整表格含 12 个模型。




SR/d 与下游性能的相关性: $r = -0.92$, $N=102$, 仅从权重即可预测性能。

💡 **关键实验**: OLMo-2-13B (13B参数, 40层) 和 OLMo-2-32B (32B参数, 64层) 具有相同 $d=5120$, 最终 SR/d 完全相同 = **0.043**。深度翻倍、参数翻倍, 压缩目标不变。


💡 **Hold-out 验证**: Mistral-7B (未参与拟合的新架构) 方形层 $SR/d = 0.040$, 完美命中。



SR/d (final) vs 隐藏维度 d 。红线: 渐近模型 $0.040 + 0.61/\sqrt{d}$ 。3 个架构族落在同一趋势上。



$\Delta H_2 \approx -2$ nats: 训练普遍移除 ~ 2 nats 的 Rényi-2 谱熵, 跨越 930x 参数范围。




PS. α 反转 — LOSS 看不到的结构退化信号


当 α 开始 **上升** ($d\alpha/dt > 0$)，模型内部结构正在被破坏——即使 loss 仍在下降。

模型	D/N	A_{MIN}	A_{FINAL}	ΔA (反转幅度)
Pythia-70M	4,261	2.60	2.60	0
Pythia-1B	297	2.52	2.78	+0.26
Pythia-2.8B	108	4.71	5.16	+0.45
OLMo-2-32B	189	2.90	5.25	+2.35
OLMo-2-13B	365	4.25	6.95	+2.71

💡 **核心发现：**大模型更脆弱。13B 的反转幅度是 2.8B 的 6 倍——大模型初始结构形成快但维持结构更难。



α 动态与 MLP/Attn 分解：小模型全面进入重尾；大模型 MLP 层结构持续退化。



P4: α -Guided 自适应学习率 — 真实数据验证

3-Way 对比实验

Pythia-410M, FineWeb-Edu 10B tokens (真实数据) , 9K steps, 2 seeds

SCHEDULE (学习率策略)	FINAL LOSS	FINAL A	DECAY START (开始衰减)
Cosine (余弦衰减)	2.931	2.683	Step 500 (6%)
WSD (恒温-稳定-衰减)	2.874	2.472	Step 7200 (80%)
α -Guided (谱信号引导)	2.877	2.442	Step 7500 (83%) $\leftarrow$ 自动

-0.054


ALOSS VS COSINE

+1.95%

BENCHMARK 提升

0

需要调的超参



左: Loss 曲线。WSD 和 α -Guided 明显优于 Cosine。
右: α 轨迹。Cosine 在 step 5K 后停滞 (LR 已太低无法继续形成结构)。

💡 α -Guided 自动在 83% 处触发 decay, 与手调的 WSD (80%) 几乎一致——但完全不需要预设"stable 比例"。

下游验证： Loss 提升 → Benchmark 提升

5 项标准 Benchmark（基准测试）

SCHEDULE	ARC-E (科学问答)	HELLASWAG (常识)	LAMBADA (语言建模)	PIQA (物理推理)	AVERAGE
Cosine	0.550	0.307	0.284	0.645	0.459
WSD	0.567	0.314	0.293	0.659	0.467
α -Guided	0.574	0.313	0.302	0.655	0.468

+1.95%
A-GUIDED VS COSINE

+6.3%
LAMBADA 单项

≈ WSD
A-GUIDED VS WSD

核心结论

- Loss 差异 (-0.054) 确实转化为可测量的下游提升 (+2%)
- α -Guided $\approx$ WSD（差异 0.1%）——验证了"自动 = 手调"
- LAMBADA（语言建模质量）上提升最大 (+6.3%)——谱引导对 LM 核心能力提升显著

关键问题： Lower loss 一定意味着 better model 吗？

一般来说，更低的 loss 并不意味着更好的模型（可能是 memorization）。

但在我们的实验中： Loss 下降 0.054 → 5 项 benchmark 全面提升 (+2%)。这说明 α -guided 带来的 loss 改善是真实的泛化质量提升，而非过拟合。

5 分钟测量 → 训练充分度判断

对 LLM360/K2-65B 做 spectral measurement（谱测量），无需任何训练日志或 benchmark。

指标	K2-65B 测量值	健康模型参考	诊断
SR/d	0.036	≥ 0.043	未收敛
α	5.09	< 4 (重尾)	结构未成熟
α reversal	$\Delta\alpha = +0.65$	≤ 0	结构退化中
D/N	21	≥ 300	数据严重不足



诊断结论：K2-65B 训练严重不充分。

独立来源验证



Benchmark 验证

K2 在 15/21 项 benchmark 上低于 Llama-2-70B（后者仅多 43% 训练数据）。



训练曲线验证

K2 论文 Figure 12 显示 MMLU、ARC、GSM8K 等指标在最终 checkpoint 仍在上升（未 plateau）。



作者自述

"K2 Diamond is only trained on 1.4 trillion tokens, compared to Llama3's 15 trillion." — K2 技术报告

结论

5 分钟 spectral 测量得到了与跑几天 benchmark + 读技术报告相同的结论

不要用 Cosine Schedule

Cosine 从训练初期就开始降低 LR（学习率）——浪费了"结构形成黄金期"。

用 WSD 或 α -Guided：保持高 LR 到 80%+，让结构充分形成后再冷却。

大模型比你想的更"懒"


Chinchilla 推荐 $D/N=20$ ，但结构成熟需要 $D/N \geq 500$ 。

大模型需要的 D/N 更多而非更少。13B 在 $D/N=365$ 仍然结构不成熟。


MLP 是瓶颈，不是 Attention

所有大模型中 Attention 层结构 $\gg$ MLP 层结构（gap 达 4-5）。

架构启发：优先增加 MLP 容量（更宽 FFN 或 MoE）。




(a) α vs D/N : 小模型遵循指数衰减；大模型集群在 $\alpha > 5$ 。(b) 相变发生在 $N \approx 1.7B$ 。




α -Guided 监控仪表盘：Loss + α + SR/d 三信号联动， α 信号指导 LR decay 时机。

训练监控仪表盘（推荐协议）


(a) Pythia-1B — well-trained (/N)




(b) Pythia-6.9B — under-trained (/N)



(c) Attn vs MLP decomposition — 1B



(d) Attn vs MLP decomposition — 6.9B



Downstream Benchmark Validation

410M 3-Way: 5 Benchmarks, 0-shot

SCHEDULE	ARC-E	HELLASWAG	LAMBADA	PIQA	WGRANDE	AVG
Cosine	0.550	0.307	0.284	0.645	0.510	0.459
WSD	0.567	0.314	0.293	0.659	0.504	0.467
α -Guided	0.574	0.313	0.302	0.655	0.498	0.468

+1.95%

A-GUIDED VS COSINE

+6.3%

LAMBADA 提升

≈ WSD

无需调参

Key Conclusion

Training loss 改善 ($\Delta = -0.054$) 确实转化为可测量的下游 benchmark 提升。这直接回答审稿人 "lower loss $\neq$ better model" 的质疑。

α -Guided = 自动版 WSD

α -Guided 与手动调参的 WSD 性能几乎一致 ($\Delta=0.11\%$), 但完全不需要指定 stable fraction — 由模型自身的光谱信号驱动 decay 时机。

💡 LAMBADA 上优势最大 (+6.3%): 光谱引导的 schedule 对语言建模核心能力 (长程依赖预测) 提升尤为显著。

总结 & 下一步

"Loss 告诉你模型多好地拟合了数据。
Spectral metrics 告诉你模型多好地组织了自己以实现泛化。"

两者都需要；只看 loss 是在盲飞。

核心 Takeaway

- 通用压缩定律： $SR/d = f(d)$ ，与规模/架构无关 — 信息论恒等式
- α 反转 = 不可见的退化信号： Loss 还在降但结构在坏
- α -Guided 匹配手调 WSD： 不需要调超参的自适应 schedule
- Post-hoc 审计： 5 分钟判断任何模型的训练充分度
- MLP 瓶颈： 大模型架构设计应优先增加 MLP 容量

进行中 & 下一步

-  **1B Scale-Up (正在运行)**
Pythia-1B 上重做 3-way 对比，验证结论在更大规模成立。ETA: 14h。
-  **因果实验 (Causality Fork)**
在 α 反转点分叉： A 遵循信号降 LR vs B 忽略信号继续训。证明 α 的因果指导价值。
-  **更多架构验证**
Gemma-2-9B、Qwen-2-7B 等。特别需要极度 over-trained 的大模型（如 Llama-3-8B）来确认"大模型能否达到 $\alpha < 3$ "。

